

Web scraping

automatize coleta de
dados da web

Vitor Mattos

Fotografem, comentem, twitterem!

@VitorMattosRj



Olá! Estava no Rio Agile?

Sim, foi show! Aliá, achei a sua apresentação a melhor. Parabéns!

Não conhecia a ferramenta até então, eu estava iniciando ainda meus estudos sobre BDD. Achei a palestra muito boa mesmo meu nível no assunto sendo muito introdutório.

que trampo foda mano, mt obrg por compartilhar esse conhecimento bro! ou mostrar isso pros devs, talvez isso ajude a engajar os caras a mudar.

Hoje tive a oportunidade de ouvir este grande cara [@VitorMattos](#)
Deixo aqui os meus parabéns, foi uma grande palestra, valeu cada minuto e espero ver mais o seu trabalho fera, parabéns !

22:46

Gostei muito da sua palestra, eu que sou iniciante não entendia bem a importância do composer, ficou muito claro que ele é muito útil e como implementar, adorei.

Obrigado por compartilhar esse tão precioso conhecimento conosco.

Nota 10!!! 🍌🍌🍌🍌🍌

12:49

Quem sou eu?

Realizador de sonhos desde 2003

Amante de opensource


Palestrante

PHP Zend Certified Engineer ([ZEND024235](#))

PHPRio (<https://telegram.me/phprio>)

CTO Lyseon Tech

Redes sociais: (VitorMattos ou VitorMattosRJ)





LYSEONTECH

A Lyseon Tech é uma cooperativa de trabalho com modelo de gestão democrática, segura e eficiente composta por profissionais de T.I. altamente qualificados e experientes no mercado. Prezamos por apresentar vantagens, tanto para o cooperado como para as empresas parceiras.

O que é?

Web scraping (web harvesting or web data extraction) is a computer software technique of extracting information from websites. Usually, such software programs simulate human exploration of the World Wide Web by either implementing low-level Hypertext Transfer Protocol (HTTP), or embedding a fully-fledged web browser, such as Internet Explorer or Mozilla Firefox. - ***Wikipedia***

Simplificando

Extrair dados de sites que não possuem API.



Simplificando

Extrair dados de sites
que possuem API com
rate-limit.



Simplificando

Coletar dados que podemos ver na internet.



O que preciso saber?

Noções básicas de HTML




O que preciso saber?

Noções básicas de HTTP



O que preciso saber?

Conhecer bem como é o fluxo para coletar os dados da fonte desejada




O site tem API, faz sentido fazer scraping?

Web Scraping não possui
rate limited



O site tem API, faz sentido fazer scraping?

Podemos fazer acesso
anônimo para coleta
de dados



O site tem API,
faz sentido
fazer scraping?

Alguns dados não estão
acessíveis via API




Porque em PHP?

Alta performance



2019-12-06

Porque em PHP?



https://w3techs.com/technologies/overview/programming_language

Porque em PHP?

Fazer scraping utilizando
uma linguagem gostosa de
se programar.




Questões éticas

API

Se tiver API, use API

Questões éticas

Nunca faça um DoS




Questões éticas

Se houver, leia o ToS do site



Questões éticas

Nunca distribua dados não autorizados



Can you read this?

Etapas do webscraping

Web Scraping segue este fluxo:

- Pegar os dados do site alvo
- Realizar o parse da informação coletada
- Tratar dados
- Armazernar informações - db, csv, text file, etc

Scraping assíncrono



 RabbitMQ

The RabbitMQ logo features an orange icon of a rabbit's head in profile, followed by the text "RabbitMQ" in a sans-serif font, where "Rabbit" is orange and "MQ" is grey.

pthread

Anatomia de um site

O que o computador vê?

Anatomia de um site


O que eu vejo?



Anatomia de um site

Developer tools

F12




The image shows a screenshot of the Chrome DevTools interface, specifically the 'Inspector' tab. The top toolbar includes icons for Console, Inspector, Debugger, Network, Style Editor, and Performance. Below the toolbar is a search bar labeled 'Search HTML'. The main area displays the DOM tree with the following structure:

```
<html>  
  <head>  
  <body style="background-color: rgb(17, 17, 17); min-width: 413px;">  
    <div class="page-loader frozen">  
    <div class="page-wrapper">  
      <div class="preview-controls">  
      <div class="sidebar">  
      <div class="sidebar-panel">  
      <article class="projector">  
        <div class="reveal-viewport notranslate theme-font-montserrat theme-color-black-mint">  
          <div class="reveal has-vertical-slides has-horizontal-slides ready block-animations-disabled">
```

Anatomia de um site

Developer tools

F12



The screenshot shows the Chrome DevTools Network tab with the following settings: Filter URLs (empty), Persist Logs (checked), Disable cache (checked), No throttling, and HAR (disabled). The network requests are as follows:

Status	Meth...	Domain	File	Cause	Type	Transferred	Size	0ms
200	GET	assets.slid.es	application-a78449050ef663e2fa4d6793d2...	stylesheet	css	70.93 KB	413.28...	157 ms
200	GET	assets.slid.es	deck-v2-e8bdfbc5bfa13f57ec6043ef9d36fb8...	stylesheet	css	22.64 KB	138.81 ...	245 ms
200	GET	assets.slid.es	application-85ef4760db995dbfd9dde5509e...	script	js	916.60 KB	916.03...	1903 ms
200	GET	assets.slid.es	editor-v2-aa03a42562ebb2f9f5e104bfe932...	script	js	1.06 MB	1.06 MB	2683 ms
200	GET	assets.slid.es	deck-3740c0acc2d6ecce79eae47501ce0be9...	script	js	319.99 KB	319.43...	1845 ms

Coleta de dados

Manualmente usando fopen, file_get_contents e outros

Utilizando cURL

Utilizando Guzzle

Utilizando pacotes especialistas em coleta de dados

Coleta de dados

Sites estáticos e sem JS

```
composer require symfony/browser-kit
```

https://symfony.com/doc/current/components/browser_kit.html

Coleta de dados

Sites estáticos e sem JS

Fazendo uma requisição

```
1 $client = new Client();  
2 $crawler = $client->request('GET', '/');
```

Coleta de dados

Sites estáticos e sem JS

Clicando em um link

```
1 $crawler = $client->request('GET', '/product/123');  
2 $link = $crawler->selectLink('Go elsewhere...')->link();  
3 $client->click($link);
```

Coleta de dados

Sites estáticos e sem JS

Navegando no histórico

```
1 $client = new Client();
2 $client->request('GET', '/');
3
4 // select and click on a link
5 $link = $crawler->selectLink('Documentation')->link();
6 $client->click($link);
7
8 // go back to home page
9 $crawler = $client->back();
10
11 // go forward to documentation page
12 $crawler = $client->forward();
```

Coleta de dados

Sites dinâmicos com JS

```
composer require behat/mink-selenium2-driver
```

<https://github.com/minkphp/MinkSelenium2Driver>

Coleta de dados

Sites dinâmicos com JS

```
1 $browser = 'firefox';
2 $url = 'http://example.com';
3
4 $mink = new Mink(array(
5     'selenium2' => new Session(
6         new Selenium2Driver($browser, null, $url)
7     ),
8 ));
9
10 $mink->getSession('selenium2')
11     ->getPage()
12     ->findLink('Chat')
13     ->click();
```

Manipulando dados

Funções de maipulação de string no PHP

Expressões regulares

Classes de DOM do PHP

Pacotes Composer para implementar seletores CSS e xpath

Pacotes que implementam uso de linguagem ubíqua

Manipulando dados

Seletores CSS e xpath

```
composer require symfony/css-selector  
composer require symfony/dom-crawler
```

https://symfony.com/doc/current/components/css_selector.html

Manipulando dados

Seletores CSS e xpath

```
$converter = new CssSelectorConverter();  
var_dump($converter->toXPath('div.item > h4 > a'));
```

Manipulando dados

Seletores CSS e xpath

```
$message = $crawler->filterXPath('//body/p')->text();

$crawler = $crawler
    ->filter('body > p')
    ->reduce(function (Crawler $node, $i) {
        // filters every other node
        return ($i % 2) == 0;
    });
```

Consumindo API

```
composer require symfony/http-client
```

https://symfony.com/doc/current/components/http_client.html

Consumindo API

```
1 $client = HttpClient::create();
2 $response = $client->request(
3     'GET',
4     'https://api.github.com/repos/symfony/symfony-docs'
5 );
6
7 $statusCode = $response->getStatusCode();
8 // $statusCode = 200
9 $contentType = $response->getHeaders()['content-type'][0];
10 // $contentType = 'application/json'
11 $content = $response->getContent();
12 // $content = '{"id":521583, "name":"symfony-docs", ...}'
13 $content = $response->toArray();
```

Salvando dados coletados


Texto

file_put_contents

```
file_put_contents('dados.txt', $dados);
```

Salvando dados coletados

Banco



The screenshot shows the PostgreSQL 12 documentation page for JSON types. The browser address bar displays the URL <https://www.postgresql.org/docs/12/datatype-json.html>. The page header includes the PostgreSQL logo and a navigation menu. The main content area shows the title "8.14. JSON Types" and a list of sub-sections: "8.14.1. JSON Input and Output Syntax", "8.14.2. Designing JSON Documents", "8.14.3. jsonb Containment and Existence", "8.14.4. jsonb Indexing", "8.14.5. Transforms", and "8.14.6. jsonpath Type".

Documentation → PostgreSQL 12
Supported Versions: [Current \(12\)](#) / [11](#) / [10](#) / [9.6](#) / [9.5](#) / [9.4](#)
Development Versions: [devel](#)
Unsupported versions: [9.3](#) / [9.2](#)

Search the documentation for...

8.14. JSON Types
[Prev](#) [Up](#) Chapter 8. Data Types [Home](#) [Next](#)

8.14. JSON Types

- 8.14.1. JSON Input and Output Syntax
- 8.14.2. Designing JSON Documents
- 8.14.3. jsonb Containment and Existence
- 8.14.4. jsonb Indexing
- 8.14.5. Transforms
- 8.14.6. jsonpath Type

Vitor Mattos

vitor@LT.coop.br
t.me/VitorMattos

