


Web scraping

Vitor Mattos

automatize coleta de dados da web

Fotografem, comentem, twitem!
@VitorMattosRJ



Olá! Estava no Rio Agile?

Sim, foi show! Aliá, achei a sua apresentação a melhor. Parabéns!

Não conhecia a ferramenta até então, eu estava iniciando ainda meus estudos sobre BDD. Aachei a palestra muito boa mesmo meu nível no assunto sendo muito introdutório.

que trampo foda mano, mt obrg por compartilhar esse conhecimento bro! ou mostrar isso pros devs, talvez isso ajude a engajar os caras a mudar.

Gostei muito da sua palestra, eu que sou iniciante não entendia bem a importância do composer, ficou muito claro que ele é muito útil e como implementar, adorei.

Obrigado por compartilhar esse tão precioso conhecimento conosco.

Nota 10!!! 🍌🍌🍌🍌😊

12:49

Hoje tive a oportunidade de ouvir este grande cara @VitorMattos Deixo aqui os meus parabéns, foi uma grande palestra, valeu cada minuto e espero ver mais o seu trabalho fera, parabéns !

22:46

Quem sou eu?

Realizador de sonhos desde 2003

Amante de opensource

Palestrante


PHP Zend Certified Engineer (**ZEND024235**)


PHPRio (**<https://telegram.me/phprio>**)


CTO Lyseon Tech

Redes sociais: (VitorMattos ou VitorMattosRJ)










O que é?

Web scraping (web harvesting or web data extraction) is a computer technique of extracting information from websites. Usually, such programs simulate human exploration of the World Wide Web by either implementing low-level Hypertext Transfer Protocol (HTTP), or emulating a fully-fledged web browser, such as Internet Explorer or Mozilla Firefox. [Wikipedia](#)


Simplificando

Extrair dados de sites que não possuem API.




Simplificando

Extrair dados de sites que possuem API com rate-limit.



Simplificando

Coletar dados que podemos ver na internet.



O que preciso saber?

Noções básicas de HTML




O que preciso saber?

Noções básicas de HTTP



O que preciso saber?
Conhecer bem como é o fluxo para
coletar os dados da fonte desejada




O site tem API, faz sentido fazer scraping?

Web Scraping não possui rate limited




O site tem API, faz sentido fazer scraping?

Podemos fazer acesso anônimo para coleta de dados



O site tem API, faz sentido fazer scraping?

Alguns dados não estão acessíveis via API




Porque em PHP?

Alta performance



Porque em PHP?



https://w3techs.com/technologies/overview/programming_language

2019-12-06

Porque em PHP?

Fazer scraping utilizando uma linguagem gostosa de se programar.



Questões éticas


Se tiver API, use API



API

Questões éticas

Nunca faça um DoS




Questões éticas

Se houver, leia o ToS do site



Questões éticas

Nunca distribua dados não autorizados



Etapas do webscraping

Web Scraping segue este fluxo:


- Pegar os dados do site alvo
- Realizar o parse da informação coletada
- Tratar dados
- Armazernar informações - db, csv, text file, etc

Scraping assíncrono



Anatomia de um site

O que o computador vê?



Anatomia de um site


O que eu vejo?



Anatomia de um site

Developer tools


F12



Anatomia de um site

Developer tools

F12



The screenshot shows the Chrome DevTools Network tab with five requests listed. The top toolbar includes icons for Console, Inspector, Debugger, Network (selected), Style Editor, and Performance. Below the toolbar, there's a 'Filter URLs' input, a 'Persist Logs' checkbox (checked), a 'Disable cache' checkbox (checked), and a 'No throttling' dropdown. The request list has columns for Status, Method, Domain, File, Cause, Type, Transferred, and Size. All requests are 200 status, GET method, and from assets.slid.es.

Status	Meth...	Domain	File	Cause	Type	Transferred	Size	0r
200	GET	assets.slid.es	application-a78449050ef663e2fa4d6793d2...	stylesheet	css	70.93 KB	413.28...	1
200	GET	assets.slid.es	deck-v2-e8bdfbc5bfa13f57ec6043ef9d36fb8...	stylesheet	css	22.64 KB	138.81 ...	2
200	GET	assets.slid.es	application-85ef4760db995dbfd9dde5509e...	script	js	916.60 KB	916.03...	1
200	GET	assets.slid.es	editor-v2-aa03a42562ebb2f9f5e104bfe932...	script	js	1.06 MB	1.06 MB	2
200	GET	assets.slid.es	deck-3740c0acc2d6ecce79eae47501ce0be9...	script	js	319.99 KB	319.43...	1

Coleta de dados

Manualmente usando fopen, file_get_contents e outros

Utilizando cURL

Utilizando Guzzle

Utilizando pacotes especialistas em coleta de dados

Coleta de dados

Sites estáticos e sem JS

composer require symfony/browser-kit

https://symfony.com/doc/current/components/browser_kit.html

Coleta de dados

Sites estáticos e sem JS

```
$client = new Client();  
$crawler = $client->request('GET', '/');
```

Fazendo uma requisição

Coleta de dados

Sites estáticos e sem JS

```
$crawler = $client->request('GET', '/product  
$link = $crawler->selectLink('Go elsewhere..  
$client->click($link);
```

Clicando em um link

Coleta de dados

Sites estáticos e sem JS

```
$client = new Client();  
$client->request('GET', '/');
```

```
// select and click on a link  
$link = $crawler->selectLink('Documentation');  
$client->click($link);
```

```
// go back to home page  
$crawler = $client->back();
```

Navegando no histórico

```
// go forward to documentation page  
$crawler = $client->forward();
```

Coleta de dados

Sites dinâmicos com JS

composer require behat/mink-selenium2-dri
<https://github.com/minkphp/MinkSelenium2Driver>

Coleta de dados

Sites dinâmicos com JS

```
$browser = 'firefox';  
$url = 'http://example.com';
```

```
$mink = new Mink(array(  
    'selenium2' => new Session(  
        new Selenium2Driver($browser, null, $i  
    ),  
));
```

```
$mink->getSession('selenium2')  
->getPage()  
->findLink('Chat')  
->click();
```

Manipulando dados

Funções de manipulação de string no PHP

Expressões regulares

Classes de DOM do PHP

Pacotes Composer para implementar seletores CSS e xpath

Pacotes que implementam uso de linguagem ubíqua

Manipulando dados

Seletores CSS e xpath

composer require symfony/css-selector

composer require symfony/dom-crawler

https://symfony.com/doc/current/components/css_selector.html

Manipulando dados

Seletores CSS e xpath

```
$converter = new CssSelectorConverter();  
var_dump($converter->toXPath('div.item > h
```

Manipulando dados

Seletores CSS e xpath

```
$message = $crawler->filterXPath('//body/p  
  
$crawler = $crawler  
->filter('body > p')  
->reduce(function (Crawler $node, $i) {  
    // filters every other node  
    return ($i % 2) == 0;  
});
```

Consumindo API

composer require symfony/http-client

https://symfony.com/doc/current/components/http_client.html

Consumindo API

```
$client = HttpClient::create();  
$response = $client->request(  
    'GET',  
    'https://api.github.com/repos/symfony/symfony',  
);
```

```
$statusCode = $response->getStatusCode();  
// $statusCode = 200  
$contentType = $response->getHeaders()['content-type'];  
// $contentType = 'application/json'  
$content = $response->getContent();  
// $content = '{"id":521583, "name":"symfony/symfony"}'  
$content = $response->toArray();
```

Salvando dados coletados


Texto

file_put_contents

```
file_put_contents('dados.txt', $dados);
```

Salvando dados coletados

Banco



The screenshot shows a web browser window with the URL <https://www.postgresql.org/docs/12/datatype-json.html>. The page header includes the PostgreSQL logo and a navigation bar. Below the header, there is a section for "Documentation → PostgreSQL 12" with links for supported versions (Current (12), 11, 10, 9.6, 9.5, 9.4), development versions (devel), and unsupported versions (9.3, 9.2). A search bar is present with the placeholder text "Search the documentation for...". The main content area is titled "8.14. JSON Types" and includes a breadcrumb trail: "Prev Up Chapter 8. Data Types Home Next". The page lists several sub-topics under "8.14. JSON Types": "8.14.1. JSON Input and Output Syntax", "8.14.2. Designing JSON Documents", "8.14.3. jsonb Containment and Existence", "8.14.4. jsonb Indexing", "8.14.5. Transforms", and "8.14.6. jsonpath Type".

Documentation → PostgreSQL 12
Supported Versions: [Current \(12\)](#) / [11](#) / [10](#) / [9.6](#) / [9.5](#) / [9.4](#)
Development Versions: [devel](#)
Unsupported versions: [9.3](#) / [9.2](#)

Search the documentation for...

8.14. JSON Types
Prev Up Chapter 8. Data Types Home Next

8.14. JSON Types

- 8.14.1. JSON Input and Output Syntax
- 8.14.2. Designing JSON Documents
- 8.14.3. jsonb Containment and Existence
- 8.14.4. jsonb Indexing
- 8.14.5. Transforms
- 8.14.6. jsonpath Type

Vitor Mattos



