


Web scraping

automatize coleta de
dados da web



web scraping
By Vitor Mattos



Vitor Mattos

Fotografem, comentem,
twitterem!

@VitorMattosRj



Olá! Estava no Rio Agile?

Sim, foi show! Aliá, achei a sua apresentação a melhor. Parabéns!

Não conhecia a ferramenta até então, eu estava iniciando ainda meus estudos sobre BDD. Achei a palestra muito boa mesmo meu nível no assunto sendo muito introdutório.

Hoje tive a oportunidade de ouvir este grande cara [@VitorMattos](#). Deixo aqui os meus parabéns, foi uma grande palestra, valeu cada minuto e espero ver mais o seu trabalho fera, parabéns !

22:46



Gostei muito da sua palestra, eu que sou iniciante não entendia bem a importância do composer, ficou muito claro que ele é muito útil e como implementar, adorei.



Quem sou eu?

Realizador de sonhos desde 2003

Amante de opensource

Palestrante

PHP Zend Certified Engineer ([ZEND024235](#))

PHPRio (<https://telegram.me/phprio>)



CTO Lyson Tech



Redes Sociais: [@lucianoalmeida](#) (no LinkedIn e no GitHub)





LYSEONTECH

A Lyseon Tech é uma cooperativa de trabalho com modelo de

gestão democrática, segura e eficiente composta por

profissionais de TI altamente qualificados e experientes no

mercado. Pretamos por apresentar soluções inovadoras



O que é?

Web scraping (web harvesting or web data extraction) is a computer software technique of extracting information from websites. Usually, such software programs simulate human

exploration of the World Wide Web by either implementing

low-level Hypertext Transfer Protocol (HTTP) or embedding

in fully-fledged web browser (such as Internet Explorer).



Simplificando

Extrair dados de sites que não possuem API.



Simplificando

Extrair dados de sites

que possuem API com

rate-limit



Simplificando

Coletar dados que podemos ver na internet.



O que preciso saber?

Noções básicas de HTML




O que preciso saber?

Noções básicas de HTTP



http://



O que preciso saber?

Conhecer bem como é o
fluxo para coletar os dados
da fonte desejada.



O site tem API,
faz sentido fazer
scraping?



Web Scraping não possui
rate limited



O site tem API,
faz sentido
fazer scraping?



Podemos fazer acesso
anônimo para coleta
de dados?



O site tem API,
faz sentido
fazer scraping?




Alguns dados não estão
acessíveis via API




Porque em PHP?

Alta performance



2019-12-06

Porque em PHP?




Porque em PHP?

Fazer scraping utilizando

uma linguagem gostosa de

se programar



Questões éticas



Se tiver API, use API



Questões éticas

Nunca faça um DoS



Bot
Request

Bot
Request

Bot
Request

Bot
Request




Questões éticas

Se houver, leia o ToS do site



Questões éticas

Nunca distribua dados não autorizados



Etapas do webscraping

Web Scraping segue este fluxo:

- Pegar os dados do site alvo
- Realizar o parse da informação coletada
- Tratar dados



Scraping assíncrono

 RabbitMQ




python




Anatomia de um site

O que o computador vê?



Anatomia de um site


O que eu vejo?



Anatomia de um site

Developer tools


F12



Anatomia de um site

Developer tools

F12



Coleta de dados

Manualmente usando fopen, file_get_contents e outros
Utilizando cURL

Utilizando Guzzle



Utilizando pacotes especializados em coleta de dados



Coleta de dados

Sites estáticos e sem JS

```
composer require symfony/browser-kit
```



Coleta de dados

Sites estáticos e sem JS

Fazendo uma requisição

```
1 $client = new Client();  
2 $crawler = $client->request('GET', '/');
```



Coleta de dados

Sites estáticos e sem JS

Clicando em um link



```
1 $crawler = $client->request('GET', '/product/123');  
2 $link = $crawler->selectLink('Go elsewhere...')->link();  
3 $client->click($link);
```



Coleta de dados

Sites estáticos e sem JS

Navegando no histórico


```
1 $client = new Client();  
2 $client->request('GET', '/');  
3
```

```
4 // select and click on a link  
5 $link = $crawler->selectLink('Documentation')->link();  
6 $client->click($link);  
7
```



Coleta de dados

Sites dinâmicos com JS



```
composer require behat/mink-selenium2-driver
```



Coleta de dados

Sites dinâmicos com JS

```
1 $browser = 'firefox';
2 $url = 'http://example.com';
3
4 $mink = new Mink(array(
5     'selenium2' => new Session(
6         new Selenium2Driver($browser, null, $url)
7     ),
8 ));
```



Manipulando dados

Funções de maipulação de string no PHP
Expressões regulares

Classes de DOM do PHP




Pacotes Composer para implementar seletores CSS e xpath

Pacotes que implementam uso de linguagem regular



Manipulando dados

Seletores CSS e xpath



```
composer require symfony/css-selector  
composer require symfony/dom-crawler
```



Manipulando dados

Seletores CSS e xpath

```
$converter = new CssSelectorConverter();
```

```
var_dump($converter->toXPath('div.item > h4 > a'));
```



Manipulando dados

Seletores CSS e xpath

```
$message = $crawler->filterXPath('//body/p')->text();  
  
$crawler = $crawler
```

```
->filter('body > p')  
->reduce(function (Crawler $node, $i) {  
    // filters every other node  
    return ($i % 2) == 0;  
},  
2);
```



Consumindo API

```
composer require symfony/http-client
```



Consumindo API

```
1 $client = HttpClient::create();
2 $response = $client->request(
3     'GET',
4     'https://api.github.com/repos/symfony/symfony-docs'
5 );
6
7 $statusCode = $response->getStatusCode();

8 // $statusCode = 200
9 $contentType = $response->getHeaders()['content-type'][0];
10 // $contentType = 'application/json'
```



Salvando dados coletados


Texto

file_put_contents

```
file_put_contents('dados.txt', $dados);
```



Salvando dados coletados



Vitor Mattos

vitor@LT.coop.br

t.me/VitorMattos

